

# ANALISIS PENERAPAN CLUSTERING TERHADAP KUALITAS TAKSONOMI TIKET HELPDESK BERBASIS RECURSIVE SPHERICAL K-MEANS

Kelompok Tugas Akhir 510

Presented by:  
Najib Alimudin Fajri - 221524053  
Septyana Agustina - 221524060

Dosen Pembimbing:  
Djoko Cahyo Utomo Lieharyani, S.Kom., M.MT.  
Dr. Transmissia Semiawan, BSCS., M.IT.

# Kasus Nyata




*E-government, E-enterprise, **Media Monitoring**, dan IT Talent Service.*



**Pada Kabayan Group, pengkategorian tiket keluhan belum berfungsi sebagai indikator instabilitas komponen seperti yang mereka harapkan.**

## Media Monitoring



# Kasus Nyata

Masalah tersebut disebabkan oleh kategori dan sub-kategori yang ada pada mitra saling tumpang tindih.

| KATEGORI       | SUB KATEGORI                                                              | TANGGAL           | DESKRIPSI                                                                                                                                                                                                                                                                                                                                                                                      |
|----------------|---------------------------------------------------------------------------|-------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Crawlback Data | Crawlback Media Sosial                                                    | 14 Oct 2025 21:13 | Klien: Heinz ABC<br>Isu: Crawlback data untuk platform <b>TikTok</b> periode Oktober 2024 – September 2025<br>Selamat sore, Tim IT, punten untuk dibantu dilakukan crawlback data untuk periode Oktober 2024 sampai September 2025 platform <b>TikTok</b> , mohon bantuannya. Terima kasih sebelumnya 🙏                                                                                        |
| Crawlback Data | Crawlback Media Sosial                                                    | 26 Aug 2025 06:07 | Klien : Garuda Indonesia<br>Isu <b>Data YouTube</b> kosong<br>selamat pagi tim IT, mohon bantuannya untuk di cek data YouTube di dashboard Garuda Indonesia karena jumlah datanya 0. Mohon bantuannya. terima kasih 🙏                                                                                                                                                                          |
| Crawlback Data | Crawlback Tiktok Comment                                                  | 07 Apr 2026 07:55 | Klien: Setwaprés Medsos<br>Isu: Crawlback Comment<br>Pagi tim IT minta tolong bantuannya untuk crawlback comment <b>medsos</b> postingan dari akun <b>TikTok</b> @officialnews khusus postingan berikut:<br><a href="https://www.tiktok.com/@officialnews/video/7625682103367257360">https://www.tiktok.com/@officialnews/video/7625682103367257360</a> (periode 6-7 april 2026). Terima kasih |
| Crawlback Data | Crawlback Youtube Comment, Crawlback Tiktok Comment, Crawlback IG Comment | 04 Apr 2026 11:57 | Klien : Pemkab Badung<br>Isu <b>Crawlback Data Komentar</b><br>Selamat siang tim IT, minta tolong bantuannya untuk <b>crawlback data komentar</b> di dashboard Pemkab Badung dari tanggal 30 Maret - 04 April 2026<br>Terima kasih 🙏                                                                                                                                                           |


# Taksonomi?

**Taksonomi merupakan sistem klasifikasi yang digunakan untuk mengelompokkan objek atau fenomena berdasarkan dimensi dan karakteristiknya, sehingga memungkinkan praktisi untuk mendeskripsikan, memahami, serta menganalisis fenomena yang diteliti**

(Kundisch dkk., 2022; Nickerson dkk., 2013)

**Mutually Exclusive**


**Collectively Exhaustive**



# Contoh Taksonomi

Sebagai contoh, suatu aplikasi bersifat *mutually exclusive* ketika diilustrasikan melalui taksonomi aplikasi seluler (*mobile application*). Salah satu dimensi yang didefinisikan adalah dimensi 'Akses' yang terdiri dari karakteristik 'Publik' dan 'Privat'. Taksonomi ini valid karena setiap aplikasi seluler secara logis hanya dapat memiliki satu status akses.

**Mutually Exclusive**






# Contoh Taksonomi

Dan Taksonomi dikatakan *collectively exhaustive*, ketika tidak ada aplikasi yang berada di luar kedua karakteristik tersebut. Sehingga setiap karakteristik merepresentasikan setiap data (aplikasi) yang ada.

**Collectively Exhaustive**






# Masalah



Menurut Nickerson dkk. (2013), pembangunan taksonomi kerap bersifat ad-hoc atau sebatas intuisi tanpa metode yang sistematis. Akibatnya, taksonomi yang dihasilkan gagal memenuhi prinsip MECE, seperti yang teridentifikasi pada kasus Kabayan Group.



**Mutually Exclusive**

**Collectively Exhaustive**

# — Solusi yang Diusulkan —


Untuk memperbaiki hal tersebut, Nickerson *dkk.* (2013) merekomendasikan dua pendekatan yaitu *empirical-to-conceptual* dan *conceptual-to-empirical*. Keduanya dievaluasi dengan pemenuhan *ending conditions*.

**empirical-to-conceptual**

Data cukup, pemahaman domain sedikit

**conceptual-to-empirical**

Data sedikit, pemahaman domain kuat







# Research Question

Sejauh mana kedalaman level taksonomi dapat terbentuk menggunakan metode *empirical-to-conceptual* dengan menggunakan algoritma *Recursive Spherical K-Means*?

## Hipotesis

**H0**

Kedalaman 2 level belum cukup atau tidak sesuai untuk memenuhi *ending condition* dari Nickerson dkk. (2013) dalam pembentukan taksonomi tiket *helpdesk* menggunakan metode *empirical-to-conceptual* dengan algoritma *Recursive Spherical K-means* (sehingga taksonomi baru memenuhi syarat pada kedalaman selain 2 level).

**H1**

Kedalaman 2 level sudah cukup dan sesuai untuk memenuhi *ending condition* dari Nickerson dkk. (2013) dalam pembentukan taksonomi tiket *helpdesk* menggunakan metode *empirical-to-conceptual* dengan algoritma *Recursive Spherical K-means*.




# Tujuan

- Menentukan variasi jumlah klaster ( $k$ ) paling optimal di setiap tingkatan hierarki melalui evaluasi *Silhouette Score*.
- Menganalisis sejauh mana kedalaman level taksonomi melalui pendekatan *empirical-to-conceptual* sesuai *ending conditions* Nickerson dkk. (2013).
- Menghasilkan taksonomi tiket *helpdesk* yang valid secara matematis maupun konseptual untuk mengatasi masalah klasifikasi *ad-hoc* dan memenuhi prinsip MECE.



# Variabel Penelitian



$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

## Kohesi Intra-klaster

$a(i)$  Rata-rata jarak antara titik data  $i$  ke anggota klaster

## Separasi Antar-klaster

$b(i)$  Rata-rata jarak antara titik data  $i$  ke klaster terdekat

## Silhouette Score

$S(i)$  mendekati 1 (klaster baik)  
mendekati 0 (batas klaster)  
mendekati -1 (klaster buruk)



# Dataset —


## Contoh Data

Klien : Jasa Marga  
Isu : Crawlback berjalan sudah lebih dari 1 jam


Selamat siang tim IT, punten mengganggu waktunya. Mau melaporkan adanya kendala terkait crawlback media online yang sudah berjalan lebih dari satu jam. Terima kasih

## Tiket Keluhan *Helpdesk* Kabayan Group

- Dataset merupakan data tiket keluhan yang berasal dari sistem *helpdesk* Kabayan Group
- Data diambil dalam rentang waktu 2024 - 2026
- Data berjumlah 1639 tiket
- Data berisi deskripsi keluhan dalam Bahasa Indonesia.
- Data terdiri dari 5 kategori dan 60 sub-kategori



# Perangkat Pendukung



## Bahasa

Python

## Library

- Pandas
- Numpy
- PyTorch
- Scikit-learn
- FAISS (Facebook AI Similarity Search), dan lain-lain.

## Tools

- Perangkat keras
- Visual Studio Code
- Draw.io
- Github.




## Ruang Lingkup

- Transformasi taksonomi *ad-hoc* menjadi *berbasis data*.
- Penggunaan IndoSBERT dan *Recursive Spherical* K-Means
- Menentukan jumlah kluster ( $k$ ) optimal menggunakan *Silhouette Score*.
- Menguji batas kedalaman taksonomi (spesifik 2 level) menggunakan prosedur *ending conditions* Nickerson dkk. (2013)


## Batasan

- Terbatas pada *dataset* tiket *helpdesk* Kabayan Group (2024-2026) sebanyak 1639 data.
- Berfokus pada penyelesaian masalah taksonomi teks, tidak mencakup masalah lainnya.
- Berfokus pada *clustering*, tidak mencakup pembuatan *User Interface* (UI) maupun integrasi langsung ke *database* mitra.






# Tahapan Penelitian



## Keterangan

-  Tahapan Mandiri
-  Tahapan dengan Tools
-  Luaran

# Analisis Karakteristik Data

Terdapat **total 1639 data tiket**, untuk setiap tiketnya memiliki

**rata-rata 35 kata**, atau

**rata-rata 62 token.**


Dengan,

**Jumlah Token paling sedikit dalam Tiket**

**5**

**Jumlah Token paling banyak dalam Tiket**

**1603**



# Analisis Karakteristik Data

Data teridentifikasi memiliki **karakteristik**:



Menggunakan bahasa  
Indonesia dan  
Operasional Internal

Cenderung mengandung kata  
sapaan dan ungkapan santun

Beberapa tiket memiliki  
struktur:

Klien: [nama klien]  
Isu: [judul isu]  
[isi laporan/tiket]

Beberapa tiket  
menyertakan tautan/link


Tiket mengandung emotikon



# Pengumpulan & Persiapan Data

Pengumpulan data dilakukan melalui permohonan langsung kepada mitra, melalui dokumen perjanjian berupa *Non-Disclosure Agreement (NDA)*.

Persiapan data dilakukan dengan membuat dua bagian *dataset* berbeda yaitu untuk *clustering* dan untuk visualisasi Word Cloud.



ilustrasi

# Penyusunan Eksperimen

Eksperimen dirancang hingga level 2 hierarki dengan rentang jumlah klaster 2 hingga 10 pada setiap level, menghasilkan 486 skenario eksperimen.

| ID    | Klaster ID (level 1) | Variabel Bebas                   |                                  | Variabel Terikat           |                            |
|-------|----------------------|----------------------------------|----------------------------------|----------------------------|----------------------------|
|       |                      | Jumlah Klaster Level 1 ( $k_1$ ) | Jumlah Klaster Level 2 ( $k_2$ ) | Silhouette Score (level 1) | Silhouette Score (level 2) |
| 1.1.1 | 2.1                  | 2                                | 2                                |                            |                            |
| 1.1.2 |                      |                                  | 3                                |                            |                            |
| 1.1.3 |                      |                                  | 4                                |                            |                            |
| 1.1.4 |                      |                                  | 5                                |                            |                            |
| 1.1.5 |                      |                                  | 6                                |                            |                            |
| 1.1.6 |                      |                                  | 7                                |                            |                            |
| 1.1.7 |                      |                                  | 8                                |                            |                            |
| 1.1.8 |                      |                                  | 9                                |                            |                            |
| 1.1.9 |                      |                                  | 10                               |                            |                            |
| 1.2.1 | 2.2                  | 2                                | 2                                |                            |                            |
| 1.2.2 |                      |                                  | 3                                |                            |                            |
| 1.2.3 |                      |                                  | 4                                |                            |                            |
| 1.2.4 |                      |                                  | 5                                |                            |                            |
| 1.2.5 |                      |                                  | 6                                |                            |                            |
| 1.2.6 |                      |                                  | 7                                |                            |                            |
| 1.2.7 |                      |                                  | 8                                |                            |                            |
| 1.2.8 |                      |                                  | 9                                |                            |                            |
| 1.2.9 |                      |                                  | 10                               |                            |                            |



# Analisis Ending Conditions



Dalam proses pembentukan taksonomi, Nickerson *dkk.* (2013) menetapkan *ending conditions* sebagai acuan untuk menentukan kapan proses iterasi pembentukan taksonomi dapat dihentikan.



*Ending conditions* tersebut terbagi menjadi dua yaitu *objective* dan *subjective ending conditions*.


**objective**

terdapat delapan *objective ending conditions*

**subjective**

terdapat lima *subjective ending conditions*

ending conditions





# Objective Ending Conditions



Dari delapan *objective ending conditions* yang didefinisikan, dipilih dua yang dapat dibuktikan secara langsung menggunakan data yang dihasilkan dalam penelitian ini.

## Nickerson *dkk.* (2013)




**Seluruh objek atau sampel representatif telah diperiksa**

**Tidak ada karakteristik yang duplikat dalam satu dimensi**

## Adaptasi dalam Penelitian

**Dibuktikan dengan menghitung jumlah total tiket pada setiap klaster yang terbentuk dibandingkan dengan total dataset yaitu 1639.**

**Dibuktikan dengan pencocokan tiga top word dari Word Cloud antar-klaster.**



# Subjective Ending Conditions

Untuk lima *subjective ending conditions* yang didefinisikan, semua kondisi akan dibuktikan secara langsung menggunakan data yang dihasilkan dalam penelitian ini.

## Nickerson *dkk.* (2013)

### Concise (ringkas)

apakah jumlah dimensi memungkinkan taksonomi bermakna tanpa menjadi terlalu rumit atau membebani, dengan panduan bahwa jumlah dimensi sebaiknya tidak melebihi batas kapasitas kognitif manusia yaitu  $7 \pm 2$ ?

### Robust (tangguh)

apakah dimensi dan karakteristik yang ada mampu membedakan antar objek secara memadai sehingga tidak ada entitas yang kehilangan spesifikasinya?

### Comprehensive (menyeluruh)

apakah seluruh objek dalam domain dapat diklasifikasikan ke dalam taksonomi yang terbentuk tanpa ada yang tertinggal?

### Extendible (dapat diperluas)

apakah dimensi baru atau karakteristik baru dari dimensi yang ada dapat ditambahkan dengan mudah seiring munculnya objek baru di masa depan?

### Explanatory (eksplanatoris)

apa yang dijelaskan oleh dimensi dan karakteristik mengenai suatu objek?

## Adaptasi dalam Penelitian

### Concise (ringkas)

dengan menetapkan rentang eksperimen jumlah kluster pada setiap level antara 2 hingga 10, di mana rentang tersebut digunakan untuk mengetahui jumlah kluster yang akan digunakan.

### Robust (tangguh)

dengan menggunakan dua metrik yaitu melihat nilai *silhouette score* kombinasi  $k$  terbaik (0-0.5), serta menghitung nilai rata-rata *cosine similarity* (mendekati 1) setiap kluster.

### Comprehensive (menyeluruh)

dengan membuat perhitungan sebagai verifikasi total tiket yang berhasil diklasifikasikan dari total dataset.


### Extendible (dapat diperluas)

dengan membandingkan nilai *silhouette score* setiap skenario  $k = n$  dengan  $k = n+1$ , sehingga mempertahankan nilai *silhouette* tertinggi.


### Explanatory (eksplanatoris)

dengan melakukan analisis kualitatif pada Word Cloud setiap kluster sebagai representasi keluhan dalam kluster tersebut.

# Alur APE



# Sentence Embedding (IndoSBERT)



Model *sentence embedding* berbasis IndoBERT (varian model BERT yang di-*fine-tune* khusus untuk bahasa Indonesia) yang dikembangkan menggunakan arsitektur *siamese network*.

1. Sliding Window

2. Tokenisasi

3. Embedding layer

4. Attention Layer


5. Pooling & Dense Layer



# Sliding Window




Karena model terbatas 256 token, tiket dengan token  $> 256$  akan diterapkan sliding window untuk menghindari hilangnya informasi






# Tokenisasi

Input teks akan dipecah menjadi unit kecil yang disebut token menggunakan algoritma *tokenizer* WordPiece (terdiri dari > 30.000 token)



# Embedding Layer

***Embedding layer*** pada model IndoSBERT dilakukan dengan menjumlahkan tiga komponen *embedding*, yaitu *token embeddings*, *segment embeddings*, dan *position embeddings*.



(Devlin dkk., 2019)

[ilustrasi perhitungan](#)

# Attention Layer

Selanjutnya *embedding matrix* akan dilakukan mekanisme *self-attention* untuk menghitung nilai korelasi antar token



$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(Vaswani dkk., 2017)

*embedding matrix* akan dikalikan dengan setiap matriks bobot yang dihasilkan selama fase *training*

[ilustrasi perhitungan](#)

# Pooling & Dense Layer



Selanjutnya pada tahap pooling & dense layer pada IndoSBERT, matriks kontekstual yang didapatkan sebelumnya akan ditransformasi menjadi satu vektor tunggal sebagai representasi satu kalimat utuh.

Pooling dilakukan dengan *mean pooling*, dengan menghitung rata-rata seluruh vektor token.

$$O_{mean} = \frac{1}{N} \sum_{i=1}^N O_i$$

Di mana:

$O_i$  = Vektor luaran hasil operasi transformasi linear yang menampung vektor *embedding* dari token ke-i.

$N$  = Jumlah token dalam satu kalimat.

$O_{mean}$  = Vektor hasil agregasi awal berdimensi  $1 \times 1024$ .

# Pooling & Dense Layer



Kemudian tahap *dense layer* dilakukan dengan melakukan transformasi linear vektor hasil *mean pooling*, melalui perkalian dengan matriks bobot pooling dan bias pooling yang dihasilkan model pada fase *training*.

Transformasi linear dilakukan dengan rumus berikut:

$$z = \sum (O_{mean} \bullet W_{pool}) + b_{pool}$$

di mana:

$z$  = Vektor luaran hasil operasi transformasi linear yang menampung nilai numerik mentah dimana koordinat fiturnya telah dipetakan ulang, sebelum akhirnya dieksekusi oleh fungsi aktivasi non-linear *tanh*.

$W_{pool}$  = Matriks parameter bobot internal *dense layer* bawaan arsitektur model.

$b_{pool}$  = Vektor parameter bias internal *dense layer* bawaan arsitektur model.



# Pooling & Dense Layer



Hasil transformasi linear kemudian dilakukan aktivasi non-linear *tanh*, sehingga menghasilkan vektor luaran final (O pooling) yang memiliki nilai dalam rentang -1 hingga 1.


$$O_{embedding} = \tanh(z)$$

di mana:

$O_{embedding}$  = Vektor luaran final dari keseluruhan tahapan pooler yang menjadi representasi kalimat utuh (*Sentence Embedding*).

$\tanh(z)$  = Proses eksekusi fungsi aktivasi non-linear yang dilakukan secara elemen demi elemen (*element-wise*) terhadap setiap koordinat nilai di dalam vektor linear  $z$ .

# Clustering (Recursive Spherical K-Means)



Variasi dari algoritma K-Means yang dirancang untuk mengatasi tantangan pengelompokkan dokumen, dengan keunggulan pada aspek kualitas solusi dan efisiensi komputasi

Cosine Similarity

Kedekatan Sudut

ilustrasi perhitungan

# Analisis Kebutuhan Fungsional APE

| ID                  | Requirement                                                                                                                                                          |
|---------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Tahap Preprocessing |                                                                                                                                                                      |
| FR-1.1              | Aplikasi dapat memuat teks deskripsi keluhan pada kolom 'DESKRIPSI' pada file .csv                                                                                   |
| FR-1.2              | Aplikasi dapat mengubah seluruh huruf pada data teks deskripsi keluhan menjadi huruf kecil ( <i>lowercase</i> )                                                      |
| FR-1.3              | Aplikasi dapat mengubah <i>newline character</i> menjadi titik dan spasi ' . ' pada data teks deskripsi keluhan                                                      |
| FR-1.4              | Aplikasi dapat menghapus label bawaan tiket (seperti teks klien atau label penanda isu/kendala) menggunakan aturan <i>Regular Expression</i> (regex)                 |
| FR-1.5              | Aplikasi dapat mengubah tautan (URL) yang diawali 'http' dan mengekstrak nama domain utamanya secara dinamis menjadi format string terstandar "tautan <nama_domain>" |
| FR-1.6              | Aplikasi dapat mengubah penyebutan nama akun media komunikasi yang diawali oleh karakter '@' menjadi kata 'nama orang' pada data teks deskripsi keluhan              |
| FR-1.7              | Aplikasi dapat mengubah penyebutan alamat email menjadi token kata "email@domain.com".                                                                               |
| FR-1.8              | Aplikasi dapat mengubah kata atau kalimat sapaan seperti 'selamat pagi', 'punteun', dan sebagainya menjadi kata 'sapaan' pada teks deskripsi keluhan                 |
| FR-1.9              | Aplikasi dapat menghapus emotikon pada data teks deskripsi keluhan                                                                                                   |
| FR-1.10             | Aplikasi dapat menghapus kata-kata yang merupakan kata hubung, kata depan, dan kata tugas bahasa Indonesia standar ('di', 'dan', 'agar', dan sebagainya)             |
| FR-1.11             | Aplikasi dapat menyimpan hasil <i>preprocessing</i> data teks deskripsi keluhan ke dalam file .txt                                                                   |

| ID                       | Requirement                                                                                                                           |
|--------------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| Tahap Sentence Embedding |                                                                                                                                       |
| FR-2.1                   | Aplikasi dapat memuat data deskripsi keluhan yang telah dilakukan <i>preprocessing</i> dari file .txt                                 |
| FR-2.2                   | Aplikasi dapat menerapkan metode <i>sliding window</i> teks secara otomatis apabila ukuran dokumen melebihi kapasitas maksimal model. |
| FR-2.3                   | Aplikasi dapat melakukan <i>encoding</i> data deskripsi keluhan menjadi vektor semantik menggunakan model <i>indoSBERT-large</i>      |
| FR-2.4                   | Aplikasi dapat menyimpan vektor semantik ke dalam file .npv                                                                           |

| ID                      | Requirement                                                                                                                                                   |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Tahap Clustering        |                                                                                                                                                               |
| FR-3.1                  | Aplikasi dapat memuat vektor semantik pada file .npv                                                                                                          |
| FR-3.2                  | Aplikasi dapat melakukan normalisasi pada vektor semantik dengan <i>L2 Norm</i>                                                                               |
| FR-3.3                  | Aplikasi dapat menjalankan <i>clustering</i> menggunakan parameter jumlah kluster (k) dengan rentang 2-10                                                     |
| FR-3.4                  | Aplikasi dapat melakukan perhitungan <i>silhouette score</i> untuk setiap <i>clustering</i> menggunakan parameter jumlah kluster (k) dengan rentang 2-10      |
| FR-3.5                  | Aplikasi dapat menjalankan <i>sub-clustering</i> untuk setiap kluster yang terbentuk pada FR-2.7 menggunakan parameter jumlah kluster (k) dengan rentang 2-10 |
| FR-3.6                  | Aplikasi dapat melakukan perhitungan <i>silhouette score</i> untuk setiap <i>sub-cluster</i> menggunakan parameter jumlah kluster (k) dengan rentang 2-10     |
| FR-3.7                  | Aplikasi dapat menganalisis nilai jumlah kluster (k) yang optimal yaitu <i>silhouette score</i> tertinggi                                                     |
| FR-3.8                  | Aplikasi dapat mengidentifikasi nilai jumlah <i>sub-cluster</i> (k) yang optimal yaitu <i>silhouette score</i> tertinggi                                      |
| Tahap Visualisasi Hasil |                                                                                                                                                               |
| FR-3.9                  | Aplikasi harus dapat membuat Word Cloud untuk setiap kluster yang terbentuk pada hasil <i>clustering</i> dengan jumlah kluster (k) yang paling optimal        |
| FR-3.10                 | Aplikasi harus dapat membuat atau <i>generate</i> Word Cloud                                                                                                  |

# Hasil Eksperimen

| ID    | Klaster ID (level 1) | Variabel Bebas                   |                                  | Variabel Terikat           |                            |
|-------|----------------------|----------------------------------|----------------------------------|----------------------------|----------------------------|
|       |                      | Jumlah Klaster Level 1 ( $k_1$ ) | Jumlah Klaster Level 2 ( $k_2$ ) | Silhouette Score (level 1) | Silhouette Score (level 2) |
| 2.1.1 | 3.1                  | 3                                | 2                                | 0.1736                     | 0.0917                     |
| 2.1.2 |                      |                                  | 3                                |                            | 0.0663                     |
| 2.1.3 |                      |                                  | 4                                |                            | 0.0680                     |
| 2.1.4 |                      |                                  | 5                                |                            | 0.0686                     |
| 2.1.5 |                      |                                  | 6                                |                            | 0.0508                     |
| 2.1.6 |                      |                                  | 7                                |                            | 0.0620                     |
| 2.1.7 |                      |                                  | 8                                |                            | 0.0539                     |
| 2.1.8 |                      |                                  | 9                                |                            | 0.0578                     |
| 2.1.9 |                      |                                  | 10                               |                            | 0.0614                     |
| 2.2.1 | 3.2                  | 3                                | 2                                | 0.1736                     | 0.1701                     |
| 2.2.2 |                      |                                  | 3                                |                            | 0.1606                     |
| 2.2.3 |                      |                                  | 4                                |                            | 0.1647                     |
| 2.2.4 |                      |                                  | 5                                |                            | 0.1234                     |
| 2.2.5 |                      |                                  | 6                                |                            | 0.1267                     |
| 2.2.6 |                      |                                  | 7                                |                            | 0.1382                     |
| 2.2.7 |                      |                                  | 8                                |                            | 0.1396                     |
| 2.2.8 |                      |                                  | 9                                |                            | 0.1404                     |
| 2.2.9 |                      |                                  | 10                               |                            | 0.1014                     |
| 2.3.1 | 3.3                  | 3                                | 2                                | 0.1736                     | 0.1571                     |
| 2.3.2 |                      |                                  | 3                                |                            | 0.1288                     |
| 2.3.3 |                      |                                  | 4                                |                            | 0.1398                     |
| 2.3.4 |                      |                                  | 5                                |                            | 0.1349                     |
| 2.3.5 |                      |                                  | 6                                |                            | 0.1163                     |
| 2.3.6 |                      |                                  | 7                                |                            | 0.1178                     |
| 2.3.7 |                      |                                  | 8                                |                            | 0.1223                     |
| 2.3.8 |                      |                                  | 9                                |                            | 0.1358                     |
| 2.3.9 |                      |                                  | 10                               |                            | 0.1376                     |

# Hasil Eksperimen Metrik Evaluasi Ending Conditions

| ID    | Robust           |                  | Obj 1 dan Comprehensive |            |          |            |
|-------|------------------|------------------|-------------------------|------------|----------|------------|
|       | cos sim intra l1 | cos sim intra l2 | n_out l1                | n_clust l1 | n_out l2 | n_clust l2 |
| ...   | ...              | ...              | ...                     | ...        | ...      | ...        |
| 2.1.1 | 0.7683           | 0.7657           | 1639                    | 1639       | 926      | 926        |
| 2.1.2 | 0.7683           | 0.7759           | 1639                    | 1639       | 926      | 926        |
| 2.1.3 | 0.7683           | 0.7812           | 1639                    | 1639       | 926      | 926        |
| 2.1.4 | 0.7683           | 0.7860           | 1639                    | 1639       | 926      | 926        |
| 2.1.5 | 0.7683           | 0.7894           | 1639                    | 1639       | 926      | 926        |
| 2.1.6 | 0.7683           | 0.7931           | 1639                    | 1639       | 926      | 926        |
| 2.1.7 | 0.7683           | 0.7948           | 1639                    | 1639       | 926      | 926        |
| 2.1.8 | 0.7683           | 0.7979           | 1639                    | 1639       | 926      | 926        |
| 2.1.9 | 0.7683           | 0.8009           | 1639                    | 1639       | 926      | 926        |
| 2.2.1 | 0.7683           | 0.8501           | 1639                    | 1639       | 322      | 322        |
| 2.2.2 | 0.7683           | 0.8571           | 1639                    | 1639       | 322      | 322        |
| 2.2.3 | 0.7683           | 0.8627           | 1639                    | 1639       | 322      | 322        |
| 2.2.4 | 0.7683           | 0.8634           | 1639                    | 1639       | 322      | 322        |




perhitungan metrik







# Pembahasan Hasil Eksperimen




# Pembahasan Hasil Eksperimen

| ID    | Klaster | $k_1$ | $k_2$ | Ending Conditions |        |        |       |       |        |        |
|-------|---------|-------|-------|-------------------|--------|--------|-------|-------|--------|--------|
|       |         |       |       | APE               | n.APE  | APE    | APE   | APE   | APE    | n.APE  |
|       |         |       |       | Obj. 1            | Obj. 2 | Conci. | Robu. | Comp. | Exten. | Expla. |
| ...   | ...     | ...   | ...   | ...               | ...    | ...    | ...   | ...   | ...    | ...    |
| 2.1.1 | 3.1     | 3     | 2     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✓      | ✓      |
| 2.1.2 |         |       | 3     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.3 |         |       | 4     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.4 |         |       | 5     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.5 |         |       | 6     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.6 |         |       | 7     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.7 |         |       | 8     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.8 |         |       | 9     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.1.9 |         |       | 10    | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.1 | 3.2     | 3     | 2     | ✓                 | ✓      | ✓      | ✓     | ✓     | ✓      | ✓      |
| 2.2.2 |         |       | 3     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.3 |         |       | 4     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.4 |         |       | 5     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.5 |         |       | 6     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.6 |         |       | 7     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.7 |         |       | 8     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.8 |         |       | 9     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.2.9 |         |       | 10    | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.1 | 3.3     | 3     | 2     | ✓                 | ✓      | ✓      | ✓     | ✓     | ✓      | ✓      |
| 2.3.2 |         |       | 3     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.3 |         |       | 4     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.4 |         |       | 5     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.5 |         |       | 6     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.6 |         |       | 7     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.7 |         |       | 8     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.8 |         |       | 9     | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| 2.3.9 |         |       | 10    | ✓                 | ✗      | ✓      | ✓     | ✓     | ✗      | ✓      |
| ...   | ...     | ...   | ...   | ...               | ...    | ...    | ...   | ...   | ...    | ...    |


| top 3 words level 1 |                                |
|---------------------|--------------------------------|
| Klaster             | words                          |
| 3.1                 | {tidak, dashboard, masuk}      |
| 3.2                 | {recording, tv, normal}        |
| 3.3                 | {crawlback, instagram, medsos} |

| top 3 words level 2 |                                |
|---------------------|--------------------------------|
| Klaster             | words                          |
| 3.1.1               | {tidak, dashboard, masuk}      |
| 3.1.2               | {tidak, dashboard, masuk}      |
| 3.2.1               | {recording, tv, tvri}          |
| 3.2.2               | {normal, rri, chanel}          |
| 3.3.1               | {scrapper, pembuatan, media}   |
| 3.3.2               | {crawlback, instagram, medsos} |

# Interpretasi dan Visualisasi



[wordcloud](#)



# Kesimpulan

**Pendekatan empirical-to-conceptual berhasil mengubah taksonomi bersifat ad hoc menjadi berbasis data**

**Struktur taksonomi yang terbentuk asimetris, di mana tidak semua klaster level 1 memiliki sub-klaster**

**Hipotesis Alternatif H1 Diterima**



# Demo








# Thank You



# Persiapan Data



[kembali](#)



# Persiapan Data

## INPUT

data postingan instagram tidak masuk. sapaan tim it, boleh dibantu untuk dicek kendala apa yang bikin postingan instagram dari link yang saya lampirkan tidak masuk? padahal postingan sudah mengandung hashtag #bps. sapaan.. tautan instagram

sapaan mas nama orang dan tim info untuk siputri tidak bisa di akses mas, minta bantu untuk di cek yaaa. sapaan

dashboard loading. sapaan tim it, sapaan ada keluhan dari pihak heinz dashboard heinz loading. sapaan tim it

## Stopword Removal

data postingan instagram tidak masuk  
postingan instagram lampirkan tidak masuk  
postingan hashtag bps instagram


siputri tidak akses

dashboard loading keluhan heinz dashboard  
heinz loading

[kembali](#)

# Persiapan Data

**Distribusi Kata dan Token Dataset Tiket Keluhan (IndoSBERT)**



[kembali](#)

# Persiapan Data

| <b>duplicate = true</b> | <b>avg silhouette l1</b> | <b>avg silhouette l2</b> | <b>max silhouette l1</b> | <b>max silhouette l2</b> |
|-------------------------|--------------------------|--------------------------|--------------------------|--------------------------|
| raw                     | 0.1304                   | 0.1068                   | 0.1565                   | 0.2645                   |
| plus rm placeholder     | 0.1280                   | 0.1111                   | 0.1610                   | 0.3606                   |
| plus mask email         | 0.1280                   | 0.1111                   | 0.1610                   | 0.3606                   |
| plus mask sapaan        | 0.1280                   | 0.1111                   | 0.1610                   | 0.3606                   |
| plus rm emot            | 0.1280                   | 0.1111                   | 0.1610                   | 0.3606                   |
| plus mask url           | 0.1290                   | 0.1157                   | 0.1651                   | 0.3910                   |
| plus sliding window     | 0.1281                   | 0.1102                   | 0.1736                   | 0.3595                   |

[kembali](#)



# Ending Conditions

| Objective Ending Condition                                                                                                 | Keterangan                                                                                                                                                                                                                                            |
|----------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Seluruh objek atau sampel representatif dari objek telah diperiksa.                                                        | Jika seluruh objek belum diperiksa, maka objek tambahan tersebut perlu dipelajari lebih lanjut.                                                                                                                                                       |
| Tidak ada objek yang digabungkan dengan objek sejenis atau dipecah menjadi beberapa objek pada iterasi terakhir.           | Jika terdapat objek yang digabungkan atau dipecah, maka dampak dari perubahan tersebut perlu diperiksa dan ditentukan apakah diperlukan perubahan pada dimensi atau kriteria karakteristik.                                                           |
| Minimal satu objek telah diklasifikasikan di bawah setiap karakteristik dari setiap dimensi.                               | Jika tidak ada objek yang ditemukan di bawah suatu karakteristik, maka taksonomi memiliki karakteristik bernilai kosong ( <i>null</i> ). Objek dengan karakteristik tersebut harus diidentifikasi atau karakteristik tersebut dihapus dari taksonomi. |
| Tidak ada dimensi atau karakteristik baru yang ditambahkan pada iterasi terakhir.                                          | Jika dimensi baru ditemukan, maka lebih banyak karakteristik dari dimensi tersebut yang dapat diidentifikasi. Jika karakteristik baru ditemukan, maka lebih banyak dimensi yang menyertakan karakteristik tersebut dapat diidentifikasi.              |
| Tidak ada dimensi atau karakteristik yang digabungkan atau dipecah pada iterasi terakhir.                                  | Jika dimensi atau karakteristik digabungkan atau dipecah, maka dampak perubahan ini perlu diperiksa dan ditentukan apakah dimensi atau karakteristik lain perlu digabungkan atau dipecah.                                                             |
| Setiap dimensi bersifat unik dan tidak berulang (artinya, tidak ada duplikasi dimensi).                                    | Jika dimensi tidak unik, maka terdapat redundansi atau duplikasi antar dimensi yang harus dieliminasi.                                                                                                                                                |
| Setiap karakteristik bersifat unik di dalam dimensinya (artinya, tidak ada duplikasi karakteristik di dalam satu dimensi). | Jika karakteristik dalam satu dimensi tidak unik, maka redundansi atau duplikasi tersebut harus dieliminasi. (Kondisi ini mengikuti prinsip <i>mutual exclusivity</i> atau saling lepas dari karakteristik).                                          |
| Setiap sel (kombinasi karakteristik) bersifat unik dan tidak berulang (artinya, tidak ada duplikasi sel).                  | Jika sel tidak unik, maka terdapat redundansi atau duplikasi pada sel yang harus dieliminasi.                                                                                                                                                         |

| Subjective Ending Condition         | Pertanyaan Pemandu                                                                                                                                                                                                                                                        |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>Concise</i> (Ringkas)            | Apakah jumlah dimensi memungkinkan taksonomi untuk bermakna tanpa menjadi terlalu rumit atau membingungkan? (Kriteria objektif yang memungkinkan untuk kondisi ini adalah jumlah dimensi berada dalam rentang $7 \pm 2$ ; Miller, 1956 dalam Nickerson <i>dkk.</i> 2013). |
| <i>Robust</i> (Tangguh)             | Apakah dimensi dan karakteristik yang terbentuk mampu memberikan pemisahan yang cukup jelas, sehingga fokus permasalahan antar-kelompok dapat dibedakan secara tegas? Berdasarkan karakteristik sampel objek, apa yang dapat disimpulkan mengenai objek-objek tersebut?   |
| <i>Comprehensive</i> (Menyeluruh)   | Apakah seluruh objek atau sampel objek (acak) di dalam ruang lingkup penelitian dapat diklasifikasikan ke dalam taksonomi? Apakah semua dimensi penting dari objek yang diteliti telah berhasil diidentifikasi?                                                           |
| <i>Extendible</i> (Dapat Diperluas) | Apakah dimensi baru atau karakteristik baru pada dimensi yang sudah ada dapat ditambahkan dengan mudah jika ditemukan objek baru di masa mendatang?                                                                                                                       |
| <i>Explanatory</i> (Eksplanatoris)  | Apakah dimensi dan karakteristik yang dirancang mampu memberikan penjelasan yang bermakna mengenai sifat dasar atau faset dari objek yang diklasifikasikan?                                                                                                               |

[kembali](#)

# Embedding Layer



## Token Embeddings

Mengubah setiap Token ID menjadi angka-angka kontinu yang mewakili esensi semantik kata tersebut.

[kembali](#)

| TOKEN     | TOKEN IDS | Dimensi |        |        |        |     |        |
|-----------|-----------|---------|--------|--------|--------|-----|--------|
|           |           | d1      | d2     | d3     | d4     | ... | d1024  |
| [CLS]     | 2         | 0.363   | -0.875 | -0.378 | 0.583  | ... | 0.978  |
| ...       | ...       | ...     | ...    | ...    | ...    | ... | ...    |
| data      | 1006      | 0.123   | 0.143  | -0.123 | 0.231  | ... | 0.212  |
| posting   | 921       | -0.543  | 0.213  | 0.234  | -0.893 | ... | 0.768  |
| ##an      | 659       | 0.768   | 0.849  | 0.968  | 0.353  | ... | 0.868  |
| instagram | 804       | 0.804   | -0.758 | 0.869  | 0.332  | ... | 0.234  |
| ...       | ...       | ...     | ...    | ...    | ...    | ... | ...    |
| [SEP]     | 3         | -0.598  | 0.250  | 0.728  | 0.879  | ... | -0.394 |

# Embedding Layer



## Segment Embeddings

Menambahkan informasi apakah suatu kata berada pada kalimat pertama (kalimat A) atau kalimat kedua (kalimat B).

[kembali](#)

| TOKEN     | TOKEN SEGMENT | Dimensi |        |        |        |     |        |
|-----------|---------------|---------|--------|--------|--------|-----|--------|
|           |               | d1      | d2     | d3     | d4     | ... | d1024  |
| [CLS]     | A             | 0.975   | -0.548 | -0.297 | -0.863 | ... | 0.387  |
| ...       | A             | ...     | ...    | ...    | ...    | ... | ...    |
| data      | A             | 0.397   | -0.043 | 0.085  | 0.976  | ... | 0.298  |
| posting   | A             | 0.753   | -0.006 | -0.014 | -0.483 | ... | 0.119  |
| ...       | A             | ...     | ...    | ...    | ...    | ... | ...    |
| [SEP]     | A             | -0.234  | 0.965  | 0.728  | 0.927  | ... | 0.255  |
| ...       | B             | ...     | ...    | ...    | ...    | ... | ...    |
| ##an      | B             | 0.768   | 0.849  | 0.968  | 0.353  | ... | 0.868  |
| instagram | B             | 0.804   | -0.758 | 0.869  | 0.332  | ... | 0.234  |
| ...       | B             | ...     | ...    | ...    | ...    | ... | ...    |
| [SEP]     | B             | -0.598  | 0.250  | 0.728  | 0.879  | ... | -0.394 |

# Embedding Layer



## Position Embeddings

Menambahkan informasi mengenai urutan atau posisi relatif setiap kata di dalam kalimat

[kembali](#)


| TOKEN     | TOKEN POSITION | Dimensi |        |        |        |     |        |
|-----------|----------------|---------|--------|--------|--------|-----|--------|
|           |                | d1      | d2     | d3     | d4     | ... | d1024  |
| [CLS]     | 0              | -0.763  | -0.134 | -0.015 | 0.097  | ... | -0.876 |
| ...       | ...            | ...     | ...    | ...    | ...    | ... | ...    |
| data      | 12             | 0.238   | 0.257  | -0.230 | 0.776  | ... | -0.234 |
| posting   | 13             | -0.003  | 0.369  | -0.075 | -0.298 | ... | 0.568  |
| ##an      | 14             | 0.207   | -0.469 | 0.735  | -0.134 | ... | 0.537  |
| instagram | 15             | -0.915  | -0.149 | 0.005  | -0.285 | ... | 0.174  |
| ...       | ...            | ...     | ...    | ...    | ...    | ... | ...    |
| [SEP]     | 50             | 0.984   | -0.246 | -0.297 | -0.567 | ... | 0.137  |

# Embedding Layer



## Penjumlahan ketiga Komponen

Kemudian ketiga vektor yang sudah dihasilkan sebelumnya dijumlahkan menjadi satu vektor statis representasi token



[kembali](#)



# Attention Layer



Pertama untuk mendapatkan matriks Q, K, V kalikan matriks X dengan matriks bobot  $W_Q$ ,  $W_K$ , dan  $W_V$

Misalkan matriks *embeddings* (X):

$$X_{[CLS]} = [0.1 \quad 0.1 \quad 0.1]$$

$$X_{data} = [0.21 \quad 0.42 \quad 0.12]$$

$$X_{posting} = [0.1 \quad 0.2 \quad 0.3]$$

$$X_{\#an} = [0.5 \quad 0.6 \quad 0.7]$$

$$X_{instagram} = [0.23 \quad 0.35 \quad 0.21]$$

$$X_{tidak} = [0.11 \quad 0.22 \quad 0.33]$$

$$X_{[SEP]} = [0.2 \quad 0.2 \quad 0.2]$$

Diberikan matriks bobot  $W_Q$ :

$$W_Q = \begin{bmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \\ 0.7 & 0.8 & 0.9 \end{bmatrix}$$

Maka, matriks Q adalah:

$$Q_{instagram} = X_{instagram} \times W_Q$$

$$Q_{instagram} = [0.23 \quad 0.35 \quad 0.21] \times \begin{bmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \\ 0.7 & 0.8 & 0.9 \end{bmatrix}$$

$$Q_{instagram} = [0.32 \quad 0.45 \quad 0.55]$$

[kembali](#)

# Attention Layer



Begitu juga dengan perhitungan matriks K, misalkan:

$$W_K = \begin{bmatrix} 0.1 & 0.1 & 0.1 \\ 0.2 & 0.2 & 0.2 \\ 0.3 & 0.2 & 0.3 \end{bmatrix}$$

Maka, matriks K adalah:

$$\begin{aligned} K_{instagram} &= X_{instagram} \times W_K \\ K_{instagram} &= [0.23 \quad 0.35 \quad 0.21] \times \begin{bmatrix} 0.1 & 0.1 & 0.1 \\ 0.2 & 0.2 & 0.2 \\ 0.3 & 0.2 & 0.3 \end{bmatrix} \\ K_{instagram} &= [0.11 \quad 0.28 \quad 0.36] \end{aligned}$$

Dan yang terakhir untuk perhitungan matriks V, misalkan:

$$W_V = \begin{bmatrix} 0.2 & 0.5 & 0.8 \\ 0.3 & 0.6 & 0.9 \\ 0.4 & 0.7 & 0.1 \end{bmatrix}$$

Maka, matriks V adalah:

$$\begin{aligned} V_{instagram} &= X_{instagram} \times W_V \\ V_{instagram} &= [0.23 \quad 0.35 \quad 0.21] \times \begin{bmatrix} 0.2 & 0.5 & 0.8 \\ 0.3 & 0.6 & 0.9 \\ 0.4 & 0.7 & 0.1 \end{bmatrix} \\ V_{instagram} &= [0.44 \quad 0.38 \quad 0.39] \end{aligned}$$

[kembali](#)

# Attention Layer



Setelah dihasilkan matriks Q, K, V untuk seluruh token, selanjutnya dihitung *attention score* dengan mengalikan matriks Q dan K melalui *dot product*:

Misalkan operasi *dot product* token 'instagram' dan '##an':

$$A_{ij} = Q_i K_j^T$$

$$A_{instagram, ##an} = Q_{instagram} K_{##an}$$

$$A_{instagram, ##an} = [0.32 \quad 0.45 \quad 0.55] \bullet [0.42 \quad 0.21 \quad 0.36]$$

$$A_{instagram, ##an} = 0.4269$$

Kemudian untuk seluruh token dilakukan perhitungan yang sama.

| Key \ Query      | [CLS]<br>j=0 | data<br>j=1 | posting<br>j=2 | ##an<br>j=3 | instagram<br>j=4 | [SEP]<br>j=5 |
|------------------|--------------|-------------|----------------|-------------|------------------|--------------|
| [CLS]<br>i=0     | 0.54         | -0.22       | 0.11           | -0.18       | 0.15             | 0.31         |
| data<br>i=1      | -0.22        | 0.68        | 0.35           | 0.18        | -0.24            | 0.12         |
| posting<br>i=2   | 0.11         | 0.35        | 0.72           | -0.29       | 0.41             | -0.19        |
| ##an<br>i=3      | -0.8         | 0.18        | -0.29          | 0.55        | 0.43             | 0.25         |
| instagram<br>i=4 | 0.15         | -0.24       | 0.41           | 0.43        | 0.65             | -0.37        |
| [SEP]<br>i=5     | 0.31         | 0.12        | -0.19          | 0.25        | -0.37            | 0.49         |

[kembali](#)

# Attention Layer



Untuk mencegah nilai hasil *dot product* melonjak, *attention score* dibagi dengan akar kuadrat dimensi vektor ( $d_K$ ).

Misalkan:

$$d_K = 3$$

Maka,

$$\sqrt{3} \approx 1.732$$

Sehingga,

$$A_{ij} = \frac{Q_i K_j^T}{\sqrt{d_K}}$$

$$A_{instagram, \#\#an} = \frac{0.43}{1.732}$$

$$A_{instagram, \#\#an} = 0.248$$

[kembali](#)

Kemudian untuk seluruh token dilakukan perhitungan yang sama.

| Key<br>Query     | [CLS]<br>j=0 | data<br>j=1 | posting<br>j=2 | ##an<br>j=3 | instagram<br>j=4 | [SEP]<br>j=5 |
|------------------|--------------|-------------|----------------|-------------|------------------|--------------|
| [CLS]<br>i=0     | 0.312        | -0.127      | 0.064          | -0.104      | 0.087            | 0.179        |
| data<br>i=1      | -0.127       | 0.393       | 0.202          | 0.104       | -0.139           | 0.069        |
| posting<br>i=2   | 0.064        | 0.202       | 0.416          | -0.167      | 0.237            | -0.110       |
| ##an<br>i=3      | -0.462       | 0.104       | -0.167         | 0.318       | 0.248            | 0.144        |
| instagram<br>i=4 | 0.087        | -0.139      | 0.237          | 0.248       | 0.375            | -0.214       |
| [SEP]<br>i=5     | 0.179        | 0.069       | -0.110         | 0.144       | -0.214           | 0.283        |

# Attention Layer



Kemudian *attention score* di normalisasi dengan fungsi *softmax* agar nilai menjadi probabilitas 0 - 1.

$$\text{Softmax}(A_{ij}) = \frac{e^{A_{ij}}}{\sum_j e^{A_{ij}}}$$

Misalkan operasi *softmax* token 'instagram' dan '##an':

$$= \frac{e^{A_{instagram, \# \# an}}}{e^{A_{instagram, [CLS]}} + e^{A_{instagram, data}} + e^{A_{instagram, posting}} + e^{A_{instagram, \# \# an}} + e^{A_{instagram, instagram}} + e^{A_{instagram, [SEP]}}}$$

Maka,

$$= \frac{e^{0.248}}{e^{0.087} + e^{-0.139} + e^{0.237} + e^{0.248} + e^{0.375} + e^{-0.214}}$$

$$= \frac{1.2814}{1.0909 + 0.8702 + 1.2674 + 1.2814 + 1.4550 + 0.8073}$$

$$\text{Softmax}(A_{belum, masuk}) = \frac{1.2814}{6.7722} \approx 0.1892$$

[kembali](#)

Kemudian untuk seluruh token dilakukan perhitungan yang sama.

| Key<br>Query     | [CLS]<br>j=0 | data<br>j=1 | posting<br>j=2 | ##an<br>j=3 | instagram<br>j=4 | [SEP]<br>j=5 | Total |
|------------------|--------------|-------------|----------------|-------------|------------------|--------------|-------|
| [CLS]<br>i=0     | 0.220        | 0.142       | 0.171          | 0.145       | 0.175            | 0.147        | 1.0   |
| data<br>i=1      | 0.137        | 0.231       | 0.191          | 0.173       | 0.136            | 0.132        | 1.0   |
| posting<br>i=2   | 0.151        | 0.173       | 0.215          | 0.120       | 0.180            | 0.161        | 1.0   |
| ##an<br>i=3      | 0.091        | 0.160       | 0.122          | 0.198       | 0.185            | 0.244        | 1.0   |
| instagram<br>i=4 | 0.161        | 0.129       | 0.187          | 0.189       | 0.215            | 0.119        | 1.0   |
| [SEP]<br>i=5     | 0.177        | 0.158       | 0.132          | 0.171       | 0.119            | 0.243        | 1.0   |



# Attention Layer



Selanjutnya untuk menghasilkan output vektor, *attention score* dikalikan dengan matriks  $V$ .

Misalkan matriks  $V$  untuk setiap token:

$$V_{[CLS]} = [0.12 \quad 0.51 \quad 0.22]$$

$$V_{data} = [0.33 \quad 0.11 \quad 0.45]$$

$$V_{posting} = [0.15 \quad 0.24 \quad 0.19]$$

$$V_{\#an} = [0.62 \quad 0.18 \quad 0.8]$$

$$V_{instagram} = [0.44 \quad 0.38 \quad 0.39]$$

$$V_{[SEP]} = [0.2 \quad 0.2 \quad 0.2]$$

Sehingga, untuk menghitung vektor output token 'instagram', adalah:

$$Output_{instagram} = \sum_{j=0}^5 A_{(j,4)} \times V_j$$

Maka,

$$\begin{aligned} Output_{instagram} &= (0.161 \times V_{[CLS]}) + (0.129 \times V_{data}) + (0.187 \times V_{posting}) \\ &\quad + (0.189 \times V_{\#an}) + (0.215 \times V_{instagram}) + (0.119 \times V_{[SEP]}) \end{aligned}$$

$$\begin{aligned} Output_{instagram} &= (0.161 \times [0.12 \quad 0.51 \quad 0.22]) + (0.129 \times [0.33 \quad 0.11 \quad 0.45]) \\ &\quad + (0.187 \times [0.15 \quad 0.24 \quad 0.19]) + (0.189 \times [0.62 \quad 0.18 \quad 0.8]) \\ &\quad + (0.215 \times [0.44 \quad 0.38 \quad 0.39]) + (0.119 \times [0.2 \quad 0.2 \quad 0.2]) \end{aligned}$$

$$Output_{instagram} = [0.4299 \quad -0.2658 \quad 0.8674] \approx Contextualized Vector$$

[kembali](#)

# Normalisasi L2



$$x_{i_{norm}} = \frac{x_i}{\|X\|_2} \quad \|X\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

Misal, diberikan:

$$X = [0.4299, -0.2658, \dots, 0.8674]$$

$x_1 \quad x_2 \quad x_{256}$

Dengan panjang:

$$\|X\|_2 = \sqrt{0.4299^2 + (-0.2658)^2 + \dots + 0.8674^2}$$


$$\|X\|_2 \approx \sqrt{37.8137}$$

$$\|X\|_2 \approx 6.1493$$

Maka,

$$X_{1_{norm}} = \frac{0.4299}{6.1493} \quad X_{2_{norm}} = \frac{-0.2658}{6.1493} \quad X_{256_{norm}} = \frac{0.8674}{6.1493}$$

$$X_{1_{norm}} \approx 0.0699 \quad X_{2_{norm}} \approx -0.0432 \quad X_{256_{norm}} \approx 0.1410$$




[kembali](#)

# Inisiasi Centroid



Misal jumlah klaster ( $k$ ) adalah 3, maka akan **dipilih** 3 vektor secara **acak** untuk ditetapkan sebagai **centroid**.



$$v_1 = [0.0699, -0.0432, \dots, 0.1410] \rightarrow c_1$$

$$v_2 = [0.0581, -0.0391, \dots, 0.1325]$$


$$v_3 = [0.0712, -0.0503, \dots, 0.1289]$$

$$v_4 = [0.0624, -0.0415, \dots, 0.1502] \rightarrow c_2$$

$$v_5 = [0.0655, -0.0488, \dots, 0.1376] \rightarrow c_3$$

[kembali](#)

# Perhitungan Jarak Antar Data



[kembali](#)

$$\text{CosineDistance}(v, c) = 1 - \text{CosineSimilarity}(v, c)$$

$$\text{CosineSimilarity}(v, c) = \frac{v \bullet c}{\|v\| \times \|c\|}$$

Selanjutnya dilakukan perhitungan jarak antara data dengan centroid.

Misal untuk jarak antara  $v_2$  dengan  $c_1$ ,

$$\text{CosineSimilarity}(v_2, c_1) = \frac{(0.0581 \times 0.0699) + (-0.0391 \times (-0.0432)) + \dots + (0.1325 \times 0.1410)}{1 \times 1}$$

$$\text{CosineSimilarity}(v_2, c_1) = 0.9820$$

$$\text{CosineDistance}(v_2, c_1) = 1 - 0.9820$$

$$\text{CosineDistance}(v_2, c_1) = 0.0180$$

Perhitungan Cosine Distance ini dilakukan untuk setiap vektor ke setiap centroid.



# Pengelompokan Data




Misalnya untuk  $v_2$ , diperoleh Cosine Distance ke masing-masing centroid:

$$\text{CosineDistance}(v_2, c_1) = 0.0180$$

$$\text{CosineDistance}(v_2, c_2) = 0.0255$$

$$\text{CosineDistance}(v_2, c_3) = 0.0412$$


Karena jarak  $v_2$  ke  $c_1$  adalah yang paling minimum, maka  $v_2$  dikelompokkan sebagai anggota dari klaster pertama.



[kembali](#)



# Perbarui Centroid



Centroid diperbarui dengan menghitung rata-rata dari koordinat seluruh anggotanya. Setelah itu, centroid dilakukan normalisasi L2 agar tetap berada di permukaan bola (sphere).

3 tahap terakhir clustering ini diulang sampai mencapai titik konvergensi, yaitu:

1. Tidak adanya perubahan posisi centroid yang signifikan.
2. Tidak ada perpindahan keanggotaan titik antar-klaster.
3. Batas maksimal iterasi telah tercapai.

[kembali](#)







# Perhitungan Metrik

## Obj 1

$n_{out\ l1} == n_{clustered\ l1}$   
AND  
 $n_{out\ l2} == n_{clustered\ l2}$

## Concise

$2 \leq k \leq 10$

## Robust

$0 \leq \text{silhouette score } l1 \text{ dan } l2 \leq 0.5$   
AND  
 $\cos \text{ sim\_intra } l1 \geq 0.75$   
AND  
 $\cos \text{ sim\_intra } l2 \geq 0.75$

## Comprehensive

$n_{out\ l1} == n_{clustered\ l1}$   
AND  
 $n_{out\ l2} == n_{clustered\ l2}$

## Extendible

$\max(\text{silhouette score})$

[kembali](#)